

Experiment: Cuantizare INT8

Selective MLP-only vs Completă

ViT-Tiny pe ImageNet-1k validation

Student:

Tudose Alexandru

Grupa 10LF333

An III, Informatică Aplicată

Coordonator:

Conf. dr. ing. Honorius Gâlmeanu

Informatică Aplicată

Cuprins

1	Introducere și Ipoteză	2
1.1	Context din Faza 3	2
2	Design Experimental	2
2.1	Configurații comparate	2
2.2	Skip patterns	2
2.3	Protocol	3
3	Rezultate	3
3.1	Acuratețe și degradare	3
3.2	Tradeoff acuratețe–memorie	4
4	Analiză și Interpretare	5
4.1	Ipoteza este confirmată parțial	5
4.2	Rezultatul remarcabil: INT8-mlp-pc depășește FP32	5
4.3	Confirmarea pattern-ului din sensitivity analysis	6
4.4	Costul: compresia memoriei	6
4.5	Latența	6
5	Concluzii și Recomandări	6

1 Introducere și Ipoteză

Acest raport documentează un experiment explorator realizat pe baza unei sugestii externe: *cuantizarea exclusivă a straturilor MLP, cu păstrarea straturilor de atenție în precizie completă, poate îmbunătăți acuratețea față de cuantizarea completă a modelului.*

Raționamentul din spatele ipotezei este că straturile de atenție (`attn.qkv`, `attn.proj`) sunt implicate în calculul scorurilor de atenție (softmax), operație sensibilă la variații numerice. Păstrarea lor în FP32 ar putea reduce acumularea erorilor de cuantizare.

1.1 Context din Faza 3

Sensitivity analysis-ul din Faza 3 oferă date relevante:

- **Straturile de atenție sunt cele mai robuste** individual: `blocks.0.attn.proj` produce o *îmbunătățire* de +0.036 pp când este cuantizat izolat.
- **Straturile MLP sunt cele mai sensibile** individual: `blocks.7.mlp.fc1` produce cea mai mare degradare (−0.092 pp).

Observație importantă: sensitivity analysis cuantizează un singur strat la un moment dat. Efectele de *interacțiune* între straturi cuantizate simultan pot fi diferite față de suma efectelor individuale. Experimentul de față testează tocmai această ipoteză în condiții de cuantizare globală.

2 Design Experimental

2.1 Configurații comparate

Tabela 1: Cele 5 configurații evaluate

Metodă	Straturi cuantizate	Nr. straturi	Granularitate
FP32	—	0	—
INT8-pt (full)	Attention + MLP	48	Per-tensor
INT8-pc (full)	Attention + MLP	48	Per-channel
INT8-mlp-pt	MLP only (fc1, fc2)	24	Per-tensor
INT8-mlp-pc	MLP only (fc1, fc2)	24	Per-channel

2.2 Skip patterns

Tabela 2: Straturi excluse de la cuantizare

Configurație	Skip patterns
Full (Faza 2–3)	<code>norm</code> , <code>cls_token</code> , <code>pos_embed</code> , <code>head</code>
MLP-only	<code>norm</code> , <code>cls_token</code> , <code>pos_embed</code> , <code>head</code> , <code>attn</code>

Adăugarea pattern-ului `attn` exclude toate straturile al căror nume conține acest șir: `blocks.*.attn.qkv` și `blocks.*.attn.proj` — câte 24 de straturi la ViT-Tiny (12 blo-

curi $\times$ 2 straturi de atenție per bloc).

2.3 Protocol

Identic cu Fazele 1–3: `vit_tiny_patch16_224`, pretrained ImageNet-1k, 50 000 imagini de validare, batch size 64, Apple M4 MPS, PyTorch 2.9.1. Toate cele 5 configurații au rulat în aceeași sesiune, pe aceleași date.

3 Rezultate

3.1 Acuratețe și degradare

Tabela 3: Rezultate complete — toate configurațiile

Metodă	Straturi	Accuracy	Δ FP32	Loss	Mem (MB)
FP32	0	75.456%	—	0.9420	21.81
INT8-pt (full)	48	75.134%	−0.322 pp	0.9563	6.62
INT8-pc (full)	48	75.424%	−0.032 pp	0.9428	6.70
INT8-mlp-pt	24	75.214%	−0.242 pp	0.9554	11.69
INT8-mlp-pc	24	75.486%	+0.030 pp	0.9423	11.73




Figura 1: Degradarea de acuratețe față de FP32 pentru fiecare configurație. Valorile negative indică degradare; valorile pozitive indică o ușoară *îmbunătățire* față de baseline. Numărul de straturi cuantizate este indicat pe fiecare bară.




Figura 2: Comparație directă: cuantizare completă (48 straturi) vs MLP-only (24 straturi), per granularitate. Linia punctată indică acuratețea FP32. MLP-only îmbunătățește acuratețea în ambele cazuri, cu cost în memorie.

3.2 Tradeoff acuratețe–memorie




Figura 3: Scatter plot: acuratețe vs memorie pentru toate configurațiile. Colțul dreapta-jos reprezintă zona ideală (acuratețe mare, memorie mică). INT8-pc (full) oferă cel mai bun raport: 6.70 MB cu -0.032 pp. INT8-mlp-pc depășește FP32 ca acuratețe, dar folosește 11.73 MB.




Figura 4: Sumar complet: acuratețe, memorie și latență pentru toate configurațiile.

4 Analiză și Interpretare

4.1 Ipoteza este confirmată parțial

Tabela 4: Verdict: MLP-only vs Full quantization

Comparație	Δ Accuracy	Verdict
INT8-mlp-pt vs INT8-pt (full)	+0.080 pp	Confirmat
INT8-mlp-pc vs INT8-pc (full)	+0.062 pp	Confirmat

Skipând straturile de atenție, acuratețea **se îmbunătățește în ambele cazuri**: +0.080 pp pentru per-tensor și +0.062 pp pentru per-channel. Ipoteza este deci **confirmată empiric**.

4.2 Rezultatul remarcabil: INT8-mlp-pc depășește FP32

INT8-mlp-pc atinge 75.486% — cu +0.030 pp *peste* FP32 baseline (75.456%). Aceasta este o valoare situată în afara intervalului de degradare și necesită interpretare atentă:

- Efect de regularizare:** Eroarea de cuantizare introdusă în straturile MLP poate acționa ca un regularizator implicit, similar cu weight noise sau dropout. Straturile de atenție, rămânând în FP32, nu perturbă mecanismul de atenție, în timp ce MLP-urile cuantizate introduc un zgomot mic care reduce over-fitting-ul pe distribuția de validare.
- Variabilitate statistică:** O diferență de +0.030 pp pe 50 000 de imagini corespunde la 15 imagini clasificate diferit. Aceasta se situează *la limita* semnificației statistice (± 0.05 pp este variabilitatea tipică între rulări).
- Interacțiuni non-liniare:** Cuantizând doar MLP-urile, eliminăm erorile care în cuantizarea completă se acumula prin mecanismul de atenție (outlierii din block 7 identificați în Faza 2 afectau și calculul scorurilor de atenție în straturile ulterioare).

4.3 Confirmarea pattern-ului din sensitivity analysis

Sensitivity analysis (Faza 3) a arătat că straturile de atenție sunt robuste individual. Acest experiment demonstrează că **concluzia se menține și la cuantizare globală**: skipând straturile de atenție (care oricum tolerează cuantizarea), câștigăm acuratețe fără un cost semnificativ.

4.4 Costul: compresia memoriei

Tabela 5: Comparație memoriei și factorului de compresie

Metodă	Mem (MB)	Reducere vs FP32	Accuracy
FP32	21.81	—	75.456%
INT8-pc (full)	6.70	3.26×	75.424%
INT8-mlp-pc	11.73	1.86×	75.486%

Prețul pentru câștigul de acuratețe este semnificativ: INT8-mlp-pc folosește 11.73 MB față de 6.70 MB pentru INT8-pc complet — o diferență de 5.03 MB. Factorul de compresie scade de la 3.26× la 1.86×

4.5 Latența

Toate variantele INT8 au o latență mai mare decât FP32 pe Apple M4 MPS (hardware fără suport INT8 nativ), ceea ce este consistent cu rezultatele din Faza 3. Diferențele de latență între full și MLP-only sunt nesemnificative (± 20 ms), deoarece dequantizarea se face oricum la nivel de strat, indiferent de numărul de straturi cuantizate.

5 Concluzii și Recomandări

1. **Ipoteza confirmată:** Cuantizarea MLP-only îmbunătățește acuratețea față de cuantizarea completă: +0.080 pp per-tensor, +0.062 pp per-channel.
2. **INT8-mlp-pc — cea mai bună acuratețe:** 75.486%, ușor peste FP32 baseline. Recomandat când acuratețea maximă primează față de compresia memoriei.
3. **INT8-pc (full) — cel mai bun raport eficiență/acuratețe:** 6.70 MB, −0.032 pp. Recomandat când constrângerea principală este memoria.
4. **Concluzie structurală validată:** Straturile de atenție în ViT-Tiny sunt robuste la cuantizare atât individual (Faza 3) cât și în context global (acest experiment). Straturile MLP sunt sursa principală de degradare.
5. **Direcție viitoare — mixed-precision optim:** Sensitivity analysis + acest experiment sugerează o strategie optimă: păstrează straturile cu MSE ridicat (block 7 MLP) în FP16/FP32, cuantizează per-channel restul straturilor MLP și toate straturile de atenție. Aceasta ar putea combina compresia maximă cu degradarea minimă.

Bibliografie

- [1] A. Dosovitskiy et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” *ICLR*, 2021. [arXiv:2010.11929](#).
- [2] M. Nagel et al., “A White Paper on Neural Network Quantization,” 2021. [arXiv:2106.08295](#).
- [3] T. Dettmers et al., “LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale,” *NeurIPS*, 2022. [arXiv:2208.07339](#).
- [4] Y. Bondarenko, M. Nagel, T. Blankevoort, “Quantizable Transformers: Removing Outliers by Helping Attention Heads Do Nothing,” *ECCV*, 2024. [arXiv:2306.12929](#).