
Faza 3: Analiză de Sensibilitate
şi Comparaţii Sistemice
ViT-Tiny pe ImageNet-1k validation
Per-Tensor vs. Per-Channel · Sensitivity per Layer

Student:

Tudose Alexandru
Grupa 10LF333
An III, Informatică Aplicată

Coordonator:

Conf. dr. ing. Honorius Gâlmeanu
Informatică Aplicată

Cuprins

1	Introducere	2
2	Metodologie	2
2.1	Experimente realizate	2
2.2	Per-tensor vs. per-channel	2
2.3	Sensitivity analysis	3
2.4	Configurație	3
3	Rezultate: Comparație Globală	3
3.1	Acuratețe și degradare	3
3.2	Timing și memorie	4
4	Rezultate: Per-Tensor vs. Per-Channel	5
4.1	Eroare de cuantizare per strat	5
4.2	Impactul asupra acurateții globale	6
5	Rezultate: Sensitivity Analysis	6
5.1	Degradare per strat	6
5.2	Top 5 cele mai sensibile straturi	6
5.3	Top 5 cele mai robuste straturi	7
5.4	Heatmap structural	7
6	Discuție	8
6.1	Sinteza celor trei faze	8
6.2	Recomandări practice	8
6.3	Limitări	8
6.4	Direcții viitoare	8
7	Concluzii	9

1 Introducere

Acest raport documentează **Faza 3** — cea mai extinsă fază experimentală a lucrării de licență. Faza 3 abordează trei întrebări lăsate deschise de fazele anterioare:

1. **Per-tensor vs. per-channel:** Cât de mult îmbunătățește cuantizarea per-channel eroarea de reconstrucție și acuratețea față de per-tensor?
2. **Sensibilitate per strat:** Care straturi individuale sunt cele mai sensibile la cuantizare? (Analiza cu un singur strat cuantizat la un moment dat.)
3. **Profilare completă:** Care este profilul real de latență, memorie RAM și dimensiune pe disk pentru toate cele 4 formate (FP32, FP16, INT8-pt, INT8-pc)?

Amploare: Faza 3 include 56 evaluări complete pe cele 50 000 de imagini ImageNet-1k validation (4 globale + 48 sensitivity + 4 timing), cu un timp total de execuție de ≈ 2.5 ore pe Apple M4.

2 Metodologie

2.1 Experimente realizate

Tabela 1: Cele 5 experimente din Faza 3

Nr.	Experiment	Evaluări
1	Acuratețe globală: FP32, FP16, INT8-pt, INT8-pc	4
2	Eroare cuantizare per strat (MSE pt vs. pc)	0 (analitic)
3	Sensitivity analysis (un strat cuantizat individual)	48
4	Timing & memory profiling	4
5	Disk footprint (serializare <code>torch.save</code>)	4
Total evaluări pe 50 000 imagini		56

2.2 Per-tensor vs. per-channel

Cuantizarea **per-tensor** (Faza 2) utilizează un singur factor de scalare per matrice de ponderi:

$$s = \frac{\max(|W|)}{127}, \quad q_{ij} = \text{round}\left(\frac{W_{ij}}{s}\right) \cdot \text{clamp}(-128, 127) \quad (1)$$

Cuantizarea **per-channel** introduce un factor de scalare per rând (canal de ieșire):

$$s_i = \frac{\max(|W_{i,:}|)}{127}, \quad q_{ij} = \text{round}\left(\frac{W_{ij}}{s_i}\right) \cdot \text{clamp}(-128, 127) \quad (2)$$

Per-channel permite fiecărui canal să se adapteze la propriul dinamic de ponderi, reducând dramatic eroarea pentru straturile cu distribuții non-uniforme (e.g., outlierii din block 7 identificați în Faza 2).

2.3 Sensitivity analysis

Pentru fiecare din cele 48 de straturi cuantizabile:

1. Se pornește de la modelul FP32 complet.
2. Se cuantizează *doar* stratul respectiv (per-tensor INT8).
3. Se evaluează acuratețea pe cele 50 000 de imagini.
4. Se restaurează stratul original.

Aceasta izolează impactul fiecărui strat individual, fără interferența cauzată de cuantizarea celorlalte straturi.

2.4 Configurație

Identică cu Fazele 1–2: `vit_tiny_patch16_224`, pretrained ImageNet-1k, batch size 64, Apple M4 MPS, PyTorch 2.9.1.

3 Rezultate: Comparație Globală

3.1 Acuratețe și degradare

Tabela 2: Acuratețe globală — toate cele 4 formate

Format	Accuracy (%)	Δ vs FP32	Loss
FP32 (baseline)	75.456	—	0.9420
FP16	75.452	−0.004 pp	0.9420
INT8 per-tensor	75.134	−0.322 pp	0.9563
INT8 per-channel	75.424	−0.032 pp	0.9428




Figura 1: Comparație globală: acuratețe absolută (stânga) și degradare față de FP32 (dreapta). INT8 per-channel recuperează aproape complet degradarea per-tensor: de la −0.322 pp la doar −0.032 pp.

Rezultat cheie: INT8 per-channel reduce degradarea cu un factor de $10\times$ față de per-tensor (0.032 pp vs. 0.322 pp), atingând o acuratețe aproape identică cu FP32.

3.2 Timing și memorie

Tabela 3: Profilare completă: latență, memorie RAM, dimensiune pe disk

Format	Latency (ms)	$\pm$ Std	RAM (MB)	Disk (MB)
FP32	200.1	± 10.5	21.81	21.87
FP16	146.4	± 6.9	10.91	10.96
INT8-pt	200.4	± 8.9	6.62	6.68
INT8-pc	199.0	± 7.6	6.70	6.77




Figura 2: Profilare completă: latență cu error bars (stânga), memorie RAM (centru), dimensiune pe disk (dreapta). FP16 este singurul format cu speedup real. INT8-pt și INT8-pc au latență similară cu FP32, dar memorie de $\approx 3.3\times$ mai mică.

Observații:

- **FP16 este cel mai rapid** (146.4 ms, speedup $1.37\times$ față de FP32) — singura metodă care reduce efectiv latența.
- **INT8-pt și INT8-pc** au latență similară cu FP32 (≈ 200 ms) — dequantizarea anulează orice beneficiu.
- **INT8 per-channel** are doar +0.08 MB overhead față de per-tensor (48 vectori de scale vs. 48 scalari) — neglijabil.
- Dimensiunea pe disk urmează aceleași proporții ca memoria RAM.

4 Rezultate: Per-Tensor vs. Per-Channel

4.1 Eroare de cuantizare per strat

Tabela 4: MSE mediu per-tensor vs. per-channel

Metrică	Per-tensor	Per-channel
MSE mediu	2.88×10^{-6}	2.30×10^{-7}
Îmbunătățire medie		11.14×
Îmbunătățire maximă	179.38×	(blocks.7.mlp.fc1)
Îmbunătățire minimă	2.04×	(blocks.8.attn.proj)




Figura 3: (Sus) MSE per strat: per-tensor (portocaliu) vs. per-channel (roșu). Per-channel reduce dramatic MSE-ul pentru toate straturile, mai ales pentru outlierii din block 7. (Jos) Factorul de îmbunătățire per strat — outlierii beneficiază cel mai mult ($> 100\times$).

Interpretare: Per-channel reduce MSE-ul cu un ordin de mărime în medie ($11.14\times$). Efectul este dramatic pentru straturile cu distribuții non-uniforme ale ponderilor:

- `blocks.7.mlp.fc1`: îmbunătățire de **179.38×** — per-tensor MSE era 3.32×10^{-5} , per-channel scade la 1.85×10^{-7} .
- Straturile cu distribuții uniforme (e.g., `blocks.8.attn.proj`) beneficiază mai puțin ($2.04\times$), deoarece per-tensor era deja suficient de precis.

4.2 Impactul asupra acurateții globale

Tabela 5: Acuratețe: per-tensor vs. per-channel

Granularitate	Accuracy	Degradare	Recuperare
FP32 (referință)	75.456%	—	—
INT8 per-tensor	75.134%	−0.322 pp	—
INT8 per-channel	75.424%	−0.032 pp	90% din degradare

Per-channel recuperează **90%** din degradarea introdusă de per-tensor, reducând-o de la −0.322 pp la doar −0.032 pp. Aceasta confirmă că outlierii din block 7 (identificați în Faza 2) erau principala sursă de degradare, iar per-channel rezolvă exact această problemă.

5 Rezultate: Sensitivity Analysis

5.1 Degradare per strat




Figura 4: Sensitivity analysis: degradare de acuratețe per strat în ordinea structurală a rețelei (blocks.0 → blocks.11, câte 4 straturi per bloc: attn.qkv, attn.proj, mlp.fc1, mlp.fc2). Fiecare bară reprezintă impactul cuantizării INT8 per-tensor a unui singur strat. Portocaliu = top 25% cele mai sensibile. Linia gri punctată = media degradării.

5.2 Top 5 cele mai sensibile straturi

Tabela 6: Cele mai sensibile 5 straturi la cuantizare individuală

Strat	Accuracy	Degradare	Tip
blocks.7.mlp.fc1	75.364%	−0.092 pp	MLP
blocks.1.mlp.fc1	75.402%	−0.054 pp	MLP
blocks.0.mlp.fc1	75.422%	−0.034 pp	MLP
blocks.7.mlp.fc2	75.426%	−0.030 pp	MLP
blocks.10.mlp.fc2	75.428%	−0.028 pp	MLP

Observație: Toate cele 5 straturi cele mai sensibile sunt mlp.fc1 sau mlp.fc2 — *niciun strat de atenție* nu apare în top. Aceasta sugerează că straturile MLP sunt fundamentale

mai sensibile la cuantizare decât straturile de atenție.

5.3 Top 5 cele mai robuste straturi

Tabela 7: Cele mai robuste 5 straturi — degradare negativă (acuratețe ușor *mai mare* după cuantizare)

Strat	Accuracy	Δ	Tip
blocks.2.mlp.fc1	75.492%	+0.036 pp	MLP
blocks.0.attn.proj	75.492%	+0.036 pp	Attention
blocks.11.mlp.fc1	75.484%	+0.028 pp	MLP
blocks.7.attn.proj	75.480%	+0.024 pp	Attention
blocks.1.mlp.fc2	75.478%	+0.022 pp	MLP

Unele straturi prezintă o acuratețe ușor *mai mare* după cuantizare. Aceasta este un efect de **regularizare**: eroarea de cuantizare introduce un zgomot mic care, pentru anumite straturi, acționează ca un regularizator implicit, similar cu dropout sau weight noise.

5.4 Heatmap structural




Figura 5: Heatmap de sensibilitate: 12 blocuri $\times$ 4 tipuri de strat. Culoarea indică degradarea de acuratețe. Blocurile timpurii (0–2) și block 7 sunt cele mai sensibile, în special straturile mlp.fc1.

Heatmap-ul relevă un pattern structural clar:

- **Straturile MLP (fc1)** sunt consistent mai sensibile decât fc2 și decât straturile de atenție.
- **Blocurile timpurii (0–2)** sunt mai sensibile decât blocurile din mijloc (3–6), probabil pentru că procesează feature-urile de nivel scăzut care sunt critice pentru clasificare.
- **Block 7** este outlier din cauza distribuției non-uniforme a ponderilor (confirmat de MSE-ul ridicat din Faza 2).
- **Straturile de atenție (attn.qkv, attn.proj)** sunt cele mai robuste — mecanismul de atenție pare inherent tolerant la cuantizare.

6 Discuție

6.1 Sinteza celor trei faze

Tabela 8: Sinteza completă: Faza 1 + Faza 2 + Faza 3

Format	Acc. (%)	Δ	Mem (MB)	Disk (MB)	Lat. (ms)
FP32	75.456	—	21.81	21.87	200.1
FP16	75.452	−0.004 pp	10.91	10.96	146.4
INT8-pt	75.134	−0.322 pp	6.62	6.68	200.4
INT8-pc	75.424	−0.032 pp	6.70	6.77	199.0

6.2 Recomandări practice

Pe baza tuturor rezultatelor din Fazele 1–3:

1. **Pentru deployment general:** FP16 (`model.half()`) este recomandarea implicită — degradare neglijabilă (−0.004 pp), $2\times$ reducere de memorie, $1.37\times$ speedup. Nu există niciun motiv practic de a nu-l adopta.
2. **Pentru constrângeri de memorie:** INT8 per-channel oferă $3.26\times$ reducere cu doar −0.032 pp degradare — cel mai bun raport eficiență/acuratețe.
3. **De evitat:** INT8 per-tensor pe modele cu outlieri (e.g., block 7 la ViT-Tiny). Per-channel rezolvă exact această problemă cu overhead neglijabil.
4. **Pentru mixed-precision viitoare:** Straturile identificate ca foarte sensibile (`blocks.7.mlp.fc1`) ar putea fi păstrate în FP16 sau FP32, în timp ce restul modelului este cuantizat la INT8.

6.3 Limitări

1. **Sensitivity analysis izolată:** Fiecare strat este cuantizat individual. Interacțiunile între straturi cuantizate simultan nu sunt capturate (efectul cumulativ poate fi non-liniar).
2. **Weight-only:** Activările rămân în FP32. Cuantizarea completă (ponderi + activări) ar putea prezenta pattern-uri diferite de sensibilitate.
3. **Un singur model:** Doar ViT-Tiny (5.7M parametri) a fost evaluat. Modele mai mari pot avea distribuții de ponderi diferite și straturi outlier în alte locuri.
4. **Hardware-specific:** Latența pe Apple M4 MPS nu include kernele INT8 native (indisponibile). Pe hardware cu suport INT8 (NVIDIA, Intel AMX), profilul de latență ar fi fundamental diferit.
5. **Variabilitate a latenței:** Măsurătorile au fost efectuate cu alte procese active, ceea ce explică std-ul de 7–11 ms. Rapoartele relative rămân valide.

6.4 Direcții viitoare

- **Mixed-precision quantization:** Cuantizare selectivă bazată pe sensibilitate — straturile din top 25% rămân în precizie mai mare.

- **Cuantizare activări:** Extinderea la cuantizarea completă (ponderi + activări) cu calibrare pe un subset de date.
- **Modele mai mari:** Evaluare pe ViT-Small (22M) sau ViT-Base (86M) pentru a verifica scalabilitatea concluziilor.
- **Quantization-Aware Training (QAT):** Fine-tuning cu cuantizare simulată pentru a recupera degradarea reziduală.

7 Concluzii

1. **Per-channel recuperează 90% din degradare:** INT8 per-channel atinge **75.424%** (doar -0.032 pp față de FP32), comparativ cu 75.134% (-0.322 pp) pentru per-tensor. Îmbunătățirea medie a MSE-ului este de **11.14×**.
2. **Outlierii rezolvați:** `blocks.7.mlp.fc1`, cel mai problematic strat din Faza 2 ($\text{MSE} = 3.32 \times 10^{-5}$), beneficiază de o îmbunătățire de **179×** cu per-channel.
3. **MLP-urile sunt cele mai sensibile:** Toate cele 5 straturi din topul sensibilității sunt `mlp.fc1` sau `mlp.fc2`. Straturile de atenție sunt robust tolerate la cuantizare.
4. **Blocurile timpurii și block 7 — cele mai critice:** Heatmap-ul de sensibilitate arată că blocurile 0–2 și block 7 au cel mai mare impact individual asupra acurateții.
5. **FP16 rămâne cel mai eficient:** Cu degradare neglijabilă (-0.004 pp), $2\times$ reducere de memorie și $1.37\times$ speedup, FP16 oferă cel mai bun raport cost/beneficiu. INT8 per-channel este recomandat doar când constrângerile de memorie impun reducerea la < 7 MB.
6. **Efect de regularizare:** Unele straturi prezintă acuratețe ușor mai mare după cuantizare ($+0.036$ pp), sugerând un efect de regularizare prin zgomot de cuantizare.

Bibliografie

- [1] A. Dosovitskiy, L. Beyer, A. Kolesnikov et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” *ICLR*, 2021. [arXiv:2010.11929](https://arxiv.org/abs/2010.11929).
- [2] B. Jacob, S. Kligys, B. Chen et al., “Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference,” *CVPR*, 2018. [arXiv:1712.05877](https://arxiv.org/abs/1712.05877).
- [3] M. Nagel, M. Fournarakis, R. A. Amjad, et al., “A White Paper on Neural Network Quantization,” 2021. [arXiv:2106.08295](https://arxiv.org/abs/2106.08295).
- [4] T. Dettmers, M. Lewis, Y. Belkada, L. Zettlemoyer, “LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale,” *NeurIPS*, 2022. [arXiv:2208.07339](https://arxiv.org/abs/2208.07339).
- [5] Y. Bondarenko, M. Nagel, T. Blankevoort, “Quantizable Transformers: Removing Outliers by Helping Attention Heads Do Nothing,” *ECCV*, 2024. [arXiv:2306.12929](https://arxiv.org/abs/2306.12929).
- [6] R. Wightman, “PyTorch Image Models (timm),” 2019. <https://github.com/rwightman/pytorch-image-models>.
- [7] O. Russakovsky, J. Deng, H. Su et al., “ImageNet Large Scale Visual Recognition Challenge,” *IJCV*, vol. 115, no. 3, pp. 211–252, 2015. [arXiv:1409.0575](https://arxiv.org/abs/1409.0575).